Bài tập thực hành 2

Yêu cầu

Dự đoán doanh thu xe hơi Hyundai dòng Elantra trong năm 2013 và đầu 2014, dựa vào dữ liệu trước đó

Dữ liệu

Dữ liệu được ghi trong file elantra.csv với các trường (Month, Year, ElantraSales, Unemployment, Queries, CPI_energy, CPI_all). Giá trị cần dự đoán sẽ là ElantraSales.

Đánh giá

Đánh giá mô hình dựa trên

- Độ đo tiêu chuẩn của ML: RMSE = $\sqrt{\text{avg}\left(y^{(n)} - \hat{y}^{(n)}\right)^2}$
- Độ đo của business requirements: Mean relative errors = $\text{avg}\left(\frac{\left|y^{(n)} - \hat{y}^{(n)}\right|}{y^{(n)}}\right) \times 100\%$

Đọc dữ liệu

In [1]:
```
import pandas as pd
import numpy as np  # thư viện cho tính toán nói chung

df = pd.read_csv('elantra.csv')
```

In [2]:
```
df.tail(10)
```

Out[2]:

	Month	Year	ElantraSales	Unemployment	Queries	CPI_energy	CPI_all
40	10	2012	14512	7.8	257	256.389	231.652
41	10	2013	14876	7.2	223	243.374	233.782
42	11	2010	8631	9.8	161	219.303	219.544
43	11	2011	12414	8.6	255	247.092	227.136
44	11	2012	15923	7.8	246	248.136	231.190
45	11	2013	16751	7.0	231	242.301	234.033
46	12	2010	13096	9.4	170	227.190	220.437
47	12	2011	13025	8.5	253	243.015	227.093
48	12	2012	19024	7.9	275	244.698	231.099
49	12	2013	21692	6.7	279	246.189	234.594

In [5]:

```
##### exercise #####
# Yêu cầu: Sắp xếp lại thứ tự các hàng dữ liệu theo tháng/năm
# Gợi ý: sử dụng df.sort_values và df.reset_index
######################
df = df.sort_values(by=['Year', 'Month'], ascending=[True, True])
df = df.reset_index(drop=True)
df.tail(10)
```

Out[5]:

	Month	Year	ElantraSales	Unemployment	Queries	CPI_energy	CPI_all
40	5	2013	25090	7.5	252	240.972	232.124
41	6	2013	22163	7.5	320	245.412	232.860
42	7	2013	23958	7.3	274	245.926	233.252
43	8	2013	24700	7.2	271	244.917	233.433
44	9	2013	19691	7.2	298	245.566	233.743
45	10	2013	14876	7.2	223	243.374	233.782
46	11	2013	16751	7.0	231	242.301	234.033
47	12	2013	21692	6.7	279	246.189	234.594
48	1	2014	15326	6.6	232	247.575	234.933
49	2	2014	16393	6.7	240	246.389	235.169

In [6]:

```
import matplotlib.pyplot as plt

plt.figure(figsize=(9,6))

plt.plot(df.ElantraSales.values)
```

```
plt.xlabel('Time index')

plt.ylabel('Sales')


# function to show the plot
plt.show()
```

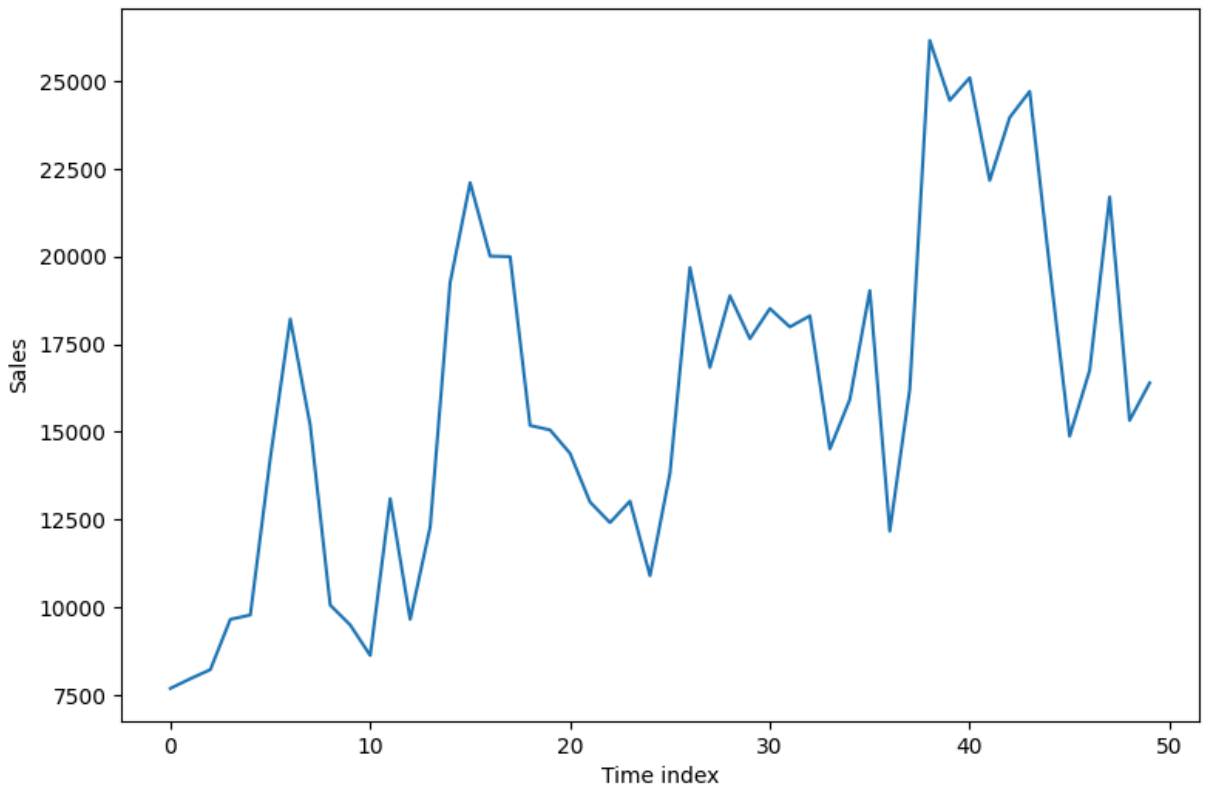

In [7]:
```
numeric_feats = df.columns.drop(["ElantraSales", "Month", "Year"])
numeric_feats
```

Out[7]:
```
Index(['Unemployment', 'Queries', 'CPI_energy', 'CPI_all'], dtype='object')
```

In [8]:
```
df_train = df[df.Year < 2013]
df_test = df[df.Year >= 2013]

y_train = df_train.ElantraSales.values
y_test = df_test.ElantraSales.values
```

feature scaling

In [9]:
```
# Chuẩn hóa dữ liệu bằng StandardScaler, dữ liệu được chuẩn hóa theo dạng x -> (x-m
# Nếu x có phân phối Gauss, dữ liệu chuẩn hóa sẽ thuộc phân phối N(0,1)
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler().fit(df_train[numeric_feats])

X_train = scaler.transform(df_train[numeric_feats])
X_test = scaler.transform(df_test[numeric_feats])
```

Xây dựng Mô hình

In [10]:
```
###### exercise #####
# Yêu cầu: Xây dựng và huấn luyện mô hình Linear Regression
# Gợi ý: sử dụng hàm fit() như trong bài thực hành 1
######################
from sklearn.linear_model import LinearRegression


model1 = LinearRegression()
model1.fit(X_train, y_train)
```

Out[10]:
```
▾ LinearRegression
▸ Parameters
```

Đánh giá

In [11]:
```
from sklearn.metrics import mean_squared_error

def relative_error(y_true, y_pred):
    errors = np.abs(y_pred - y_true).astype(float) / y_true
    return np.mean(errors)*100
```

In [12]:
```
y_pred_test = model1.predict(X_test)
print ('RMSE: {:.2f}'.format(np.sqrt(mean_squared_error(y_test, y_pred_test))))
print ('Mean relative errors: {:.1f}%'.format(relative_error(y_test, y_pred_test)))
```

```
RMSE: 5017.35
Mean relative errors: 19.0%
```

In [13]:
```
###### exercise #####
# Yêu cầu: Vẽ biểu đồ đường so sánh y_test và y_pred_test
# Gợi ý: sử dụng matplotlib như bài thực hành 1
######################
plt.figure(figsize=(9,6))
plt.plot(y_test, label='True values')
plt.plot(y_pred_test, label='Predicted values')
plt.xlabel('Time index')
plt.ylabel('Sales')
plt.legend()
plt.show()
```

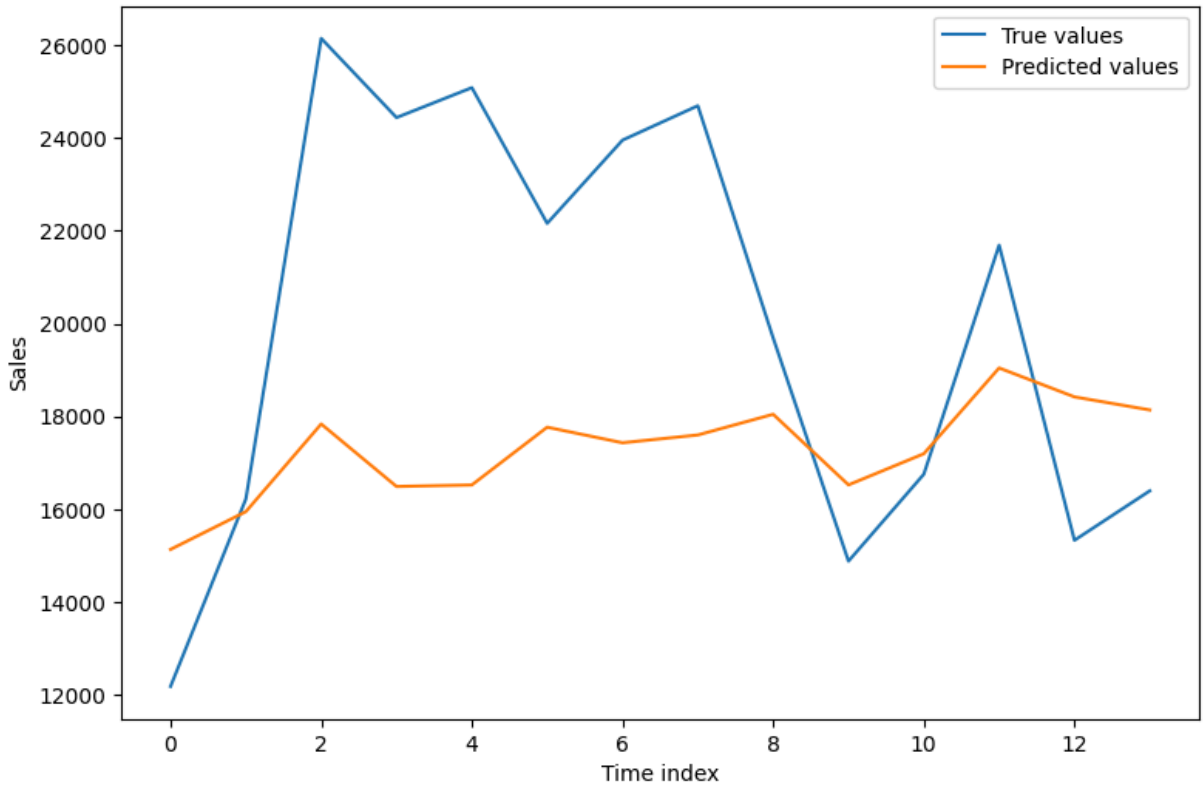

Kết quả dự đoán không khớp một chút nào so với dữ liệu thật

Lý do có thể là vì chúng ta chưa tận dụng hết thông tin của dữ liệu

Quan sát thấy doanh thu có xu hướng biến động theo từ tháng trong một năm

=> Tận dụng thông tin tháng hiệu quả. Có thể xây dựng mô hình regression với đặc trưng Month theo kiểu categorical kết hợp với các đặc trưng khác.

Giải pháp cải tiến

In [14]:
```
month_onehot_train = pd.get_dummies(df_train.Month)
month_onehot_train.head()
```

Out[14]:

	1	2	3	4	5	6	7	8	9	10	11	12
0	True	False	False	False	False	False	False	False	False	False	False	False
1	False	True	False	False	False	False	False	False	False	False	False	False
2	False	False	True	False	False	False	False	False	False	False	False	False
3	False	False	False	True	False	False	False	False	False	False	False	False
4	False	False	False	False	True	False	False	False	False	False	False	False

In [15]:
```
###### exercise #####
# Yêu cầu: Ghép đặc trưng Month_1, ..., Month_12 vào các đặc trưng đang có, kết quả
```

```
# Gợi ý: sử dụng np.hstack
######################
month_onehot_test = pd.get_dummies(df_test.Month)
X_train = np.hstack([X_train, month_onehot_train])
```

In [16]:
```
# Tương tự với X_test
X_test = np.hstack((X_test, pd.get_dummies(df_test.Month)))
```

In [17]:
```
model1.fit(X_train, y_train)
```

Out[17]:
```
▾ LinearRegression
▸ Parameters
```

In [18]:
```
y_pred_test = model1.predict(X_test)
print ('RMSE: {:.2f}'.format(np.sqrt(mean_squared_error(y_test, y_pred_test))))
print ('Mean relative errors: {:.1f}%'.format(relative_error(y_test, y_pred_test)))
```

```
RMSE: 3590.37
Mean relative errors: 12.8%
```

In [19]:
```
plt.figure(figsize=(9,6))

plt.plot(y_test)
plt.plot(y_pred_test)

plt.xlabel('Time index')

plt.ylabel('Sales')


# function to show the plot
plt.show()
```

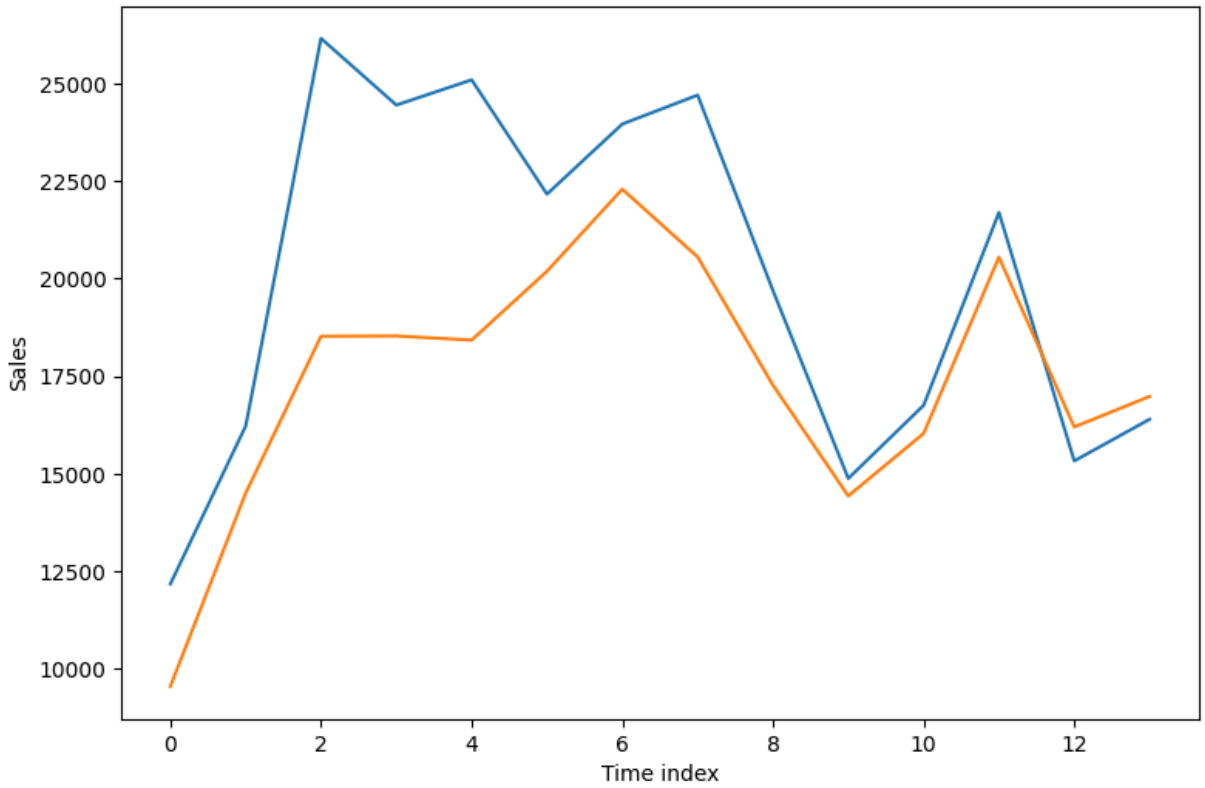
25000
22500
20000
17500
15000
12500
10000
Sales
0
2
4
6
8
10
12
Time index